



IMD0033 - Probabilidade Aula 10 - Análise Exploratória de Dados III

Ivanovitch Silva Agosto, 2017

Agenda

- Estudo de caso: analisando filmes
- Motivação: enviesamento de dados
- Histograma e gráfico de caixa



Atualizar o repositório

git clone https://github.com/ivanovitchm/IMD0033_Probabilidade.git

Ou

git pull



Estudo de caso: avaliando filmes



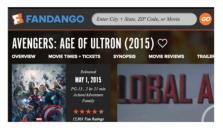
IMDB



Rotten Tomatoes



Fandango







Enviesamento de dados











Conjunto de dados

	FILM	RT_user_norm	Metacritic_user_nom	IMDB_norm	Fandango_Ratingvalue	Fandango_Stars
0	Avengers: Age of Ultron (2015)	4.3	3.55	3.90	4.5	5.0
1	Cinderella (2015)	4.0	3.75	3.55	4.5	5.0
2	Ant-Man (2015)	4.5	4.05	3.90	4.5	5.0
3	Do You Believe? (2015)	4.2	2.35	2.70	4.5	5.0
4	Hot Tub Time Machine 2 (2015)	1.4	1.70	2.55	3.0	3.5

https://github.com/fivethirtyeight/data/tree/master/fandango



Distribuição de frequências

Frequency Distribution (sorted by frequency in descending order)

Value	Frequency
4.1	16
4.2	12
3.9	12
4.3	11
3.7	9
3.5	9
4.5	9
3.4	9
3.6	8
4.4	7
4.0	7
3.2	5
2.9	5
3.8	5
3.3	4
4.6	4
3.0	4
4.8	3
3.1	3
2.8	2
2.7	2

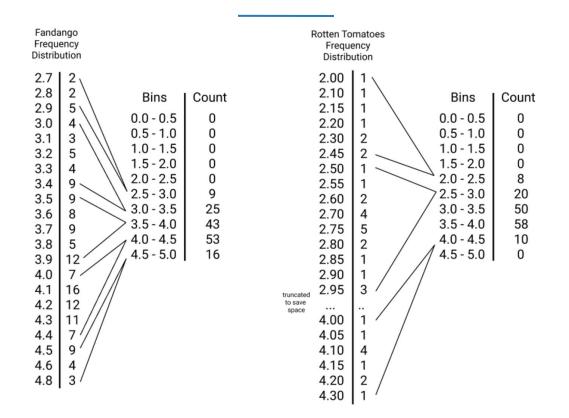
Frequency Distribution (sorted by unique value in ascending order)

Value	Frequency
2.7	2
2.8	2
2.9	5
3.0	4
3.1	3
3.2	5
3.3	4
3.4	9
3.5	9
3.6	8
3.7	9
3.8	5
3.9	12
4.0	7
4.1	16
4.2	12
4.3	11
4.4	7
4.5	9
4.6	4
4.8	3

Name: Fandango_Ratingvalue, dtype: int64

Name: Fandango_Ratingvalue, dtype: int64

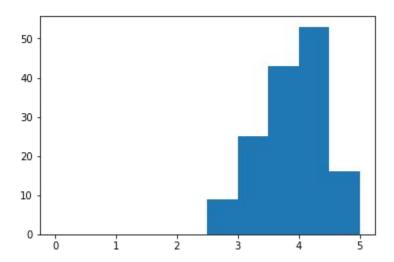
Intervalos de agrupamento





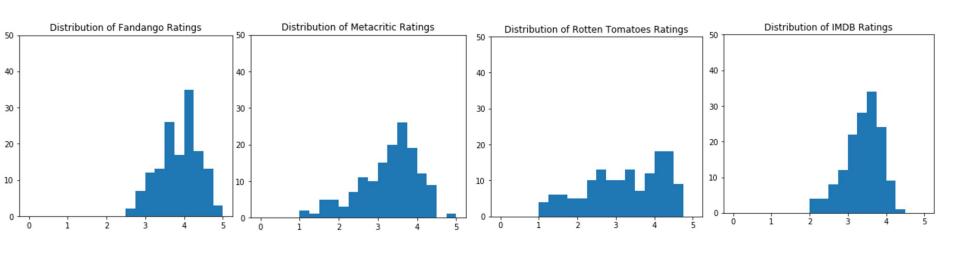
Histograma no Matplotlib

ax.hist(norm_reviews['Fandango_Ratingvalue'], range=(0, 5))





Comparando histogramas



50% das avaliações

estão entre 2 e 4

75% das avaliações

estão entre 2 e 4

50% das avaliações

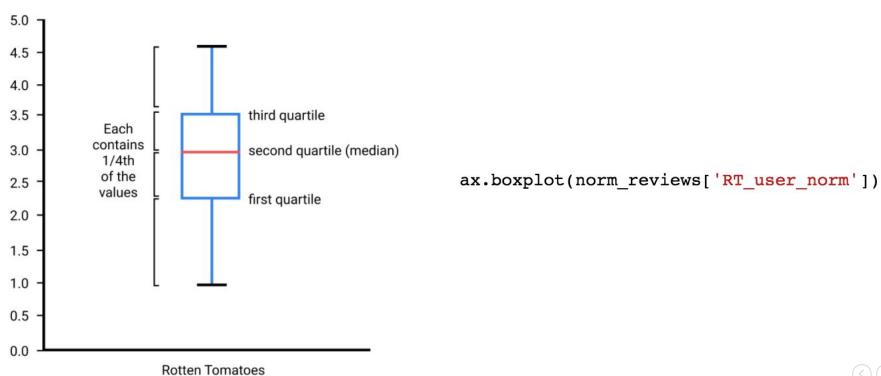
estão entre 2 e 4

()()

90% das avaliações

estão entre 2 e 4

Quartil e gráfico de caixa





Múltiplos gráficos de caixa

